

# Perceptrón Simple y Multicapa



# Integrantes



Azul Kim



Felipe Cupitó



Juan Manuel De  
Luca



Hernán Finucci



Sol Konfederak



1

# Perceptrón Simple Escalonado

AND y XOR

# Datos de entrada y salida

## AND

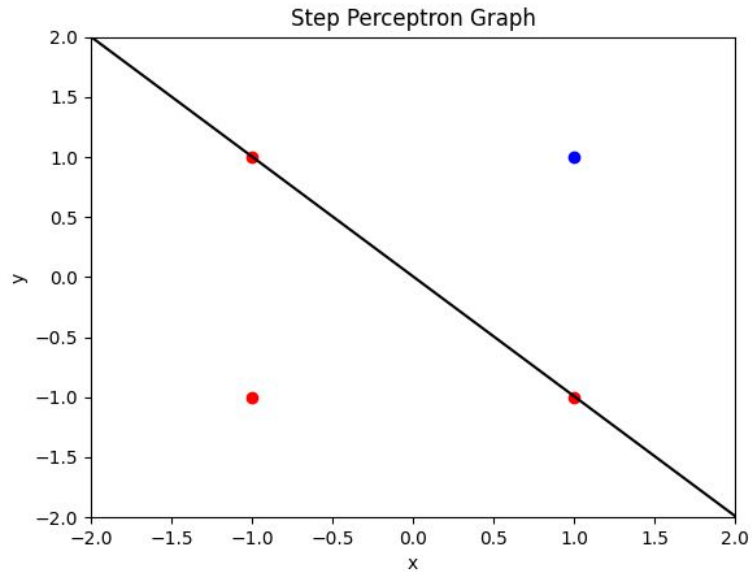
$\xi^{\mu}$	$\xi^{\mu}$	$\zeta^{\mu}$
-1	1	-1
1	-1	-1
-1	-1	-1
1	1	1

## XOR

$\xi^{\mu}$	$\xi^{\mu}$	$\zeta^{\mu}$
-1	1	1
1	-1	1
-1	-1	-1
1	1	-1

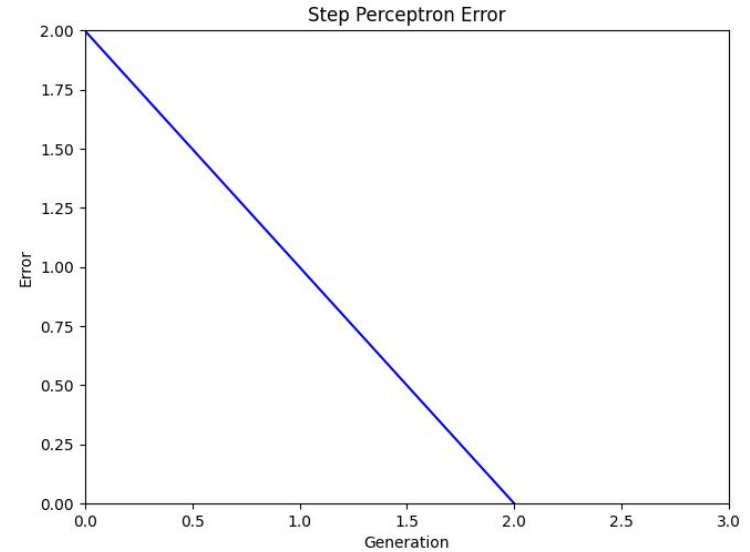


# AND - Gráfico



$\eta = 0,001$

Epochs = 1000




Error mín = 0

$w_{\min} = [0,43 \ 0,43 \ -0,004]$

# AND - Comparación de $\eta$


Step Perceptron Graph



$\eta = 0,001$

Epochs = 1000

Step Perceptron Graph




$\eta = 0,1$

Epochs = 1000

# AND - Comparación de epochs


Step Perceptron Graph



$\eta = 0,001$

Epochs = 100

Step Perceptron Graph




$\eta = 0,001$

Epochs = 1000

# XOR - Gráfico


Step Perceptron Graph



$\eta = 0,001$

Epochs = 1000

Step Perceptron Error




Error mín = 1

$w_{\min} = [-0,002 -0,003 0,001]$



# XOR - Resultado esperado



# Conclusiones

## AND

Es un problema *linealmente* separable (se puede trazar una recta que separa las dos clases de datos).

## XOR

No es un problema que se pueda resolver con este tipo de perceptrón, se requiere de dos rectas que separen las dos categorías.

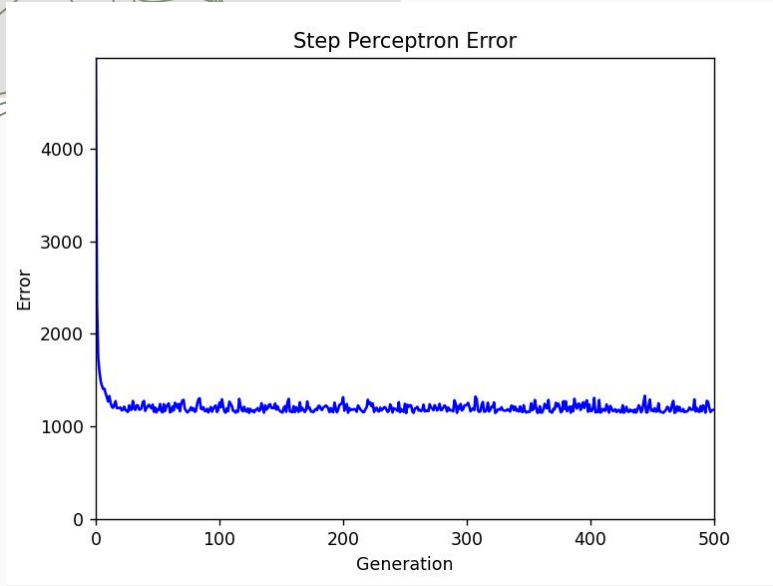


The background features a light gray base with several decorative elements: a green circle in the top left containing a line drawing of a flower; a large gray circle in the top right; a cluster of small green dots in the upper right; an orange circle in the bottom left; and a purple circle in the bottom right containing a line drawing of a flower. A central gray circle contains the number 2.

2

# Perceptron Simple Lineal y No Lineal

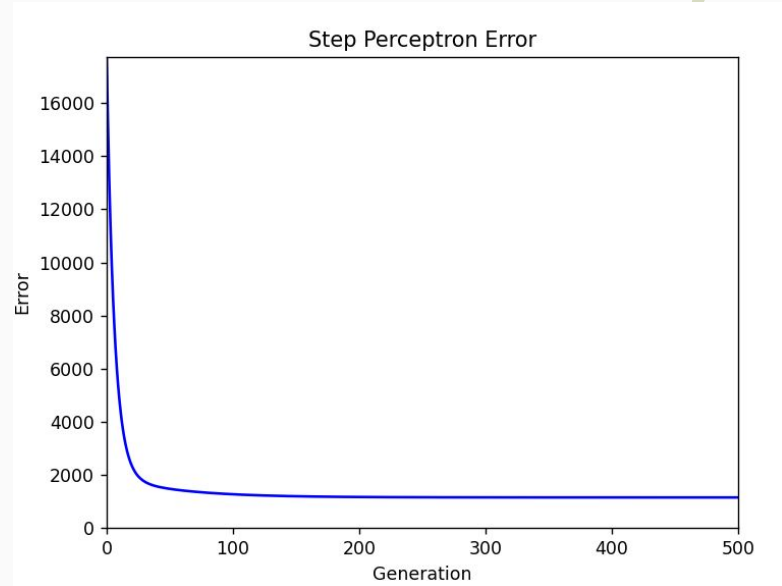
# Perceptrón simple lineal (según $\eta$ )



$\eta = 0,01$

$\beta = 0,8$

Epochs = 500




$\eta = 0,001$

$\beta = 0,8$

Epochs = 500


# Perceptrón simple no lineal (según $\eta$ )



$\eta = 0,01$

$\beta = 0,8$

Epochs = 500




$\eta = 0,001$

$\beta = 0,8$

Epochs = 500

# No lineal - Comparación de errores



$\eta = 0,01$

Epochs = 500


$\beta = 0,8$

Rojo -> error del test set

Azul -> error del training set

$\beta = 0,8$

## Porcentaje de datos de entrenamiento



# Conclusiones

Sobre la capacidad de cada perceptrón para aprender la función:

- Si se observan los gráficos de error se puede ver que la capacidad de aprendizaje aumenta ya que el error disminuye.

Sobre el conjunto de entrenamiento:

- La elección del mejor conjunto de entrenamiento dependerá de cuál es el que menor error presenta.



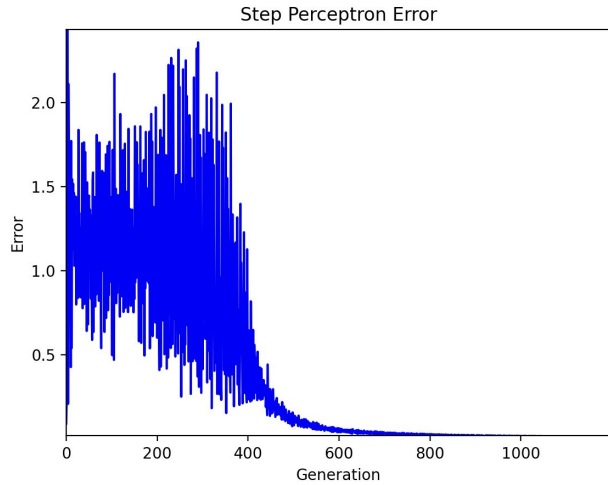


The background features a light gray base with several decorative elements: a green circle in the top-left containing a line-art flower, a large gray circle in the top-right, a cluster of small green dots in the top-right, an orange circle in the bottom-left, and a purple circle in the bottom-right containing a line-art flower.



3

# Perceptron Multicapa

# Funcion XOR


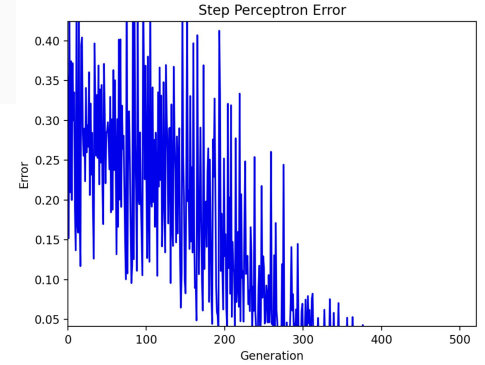
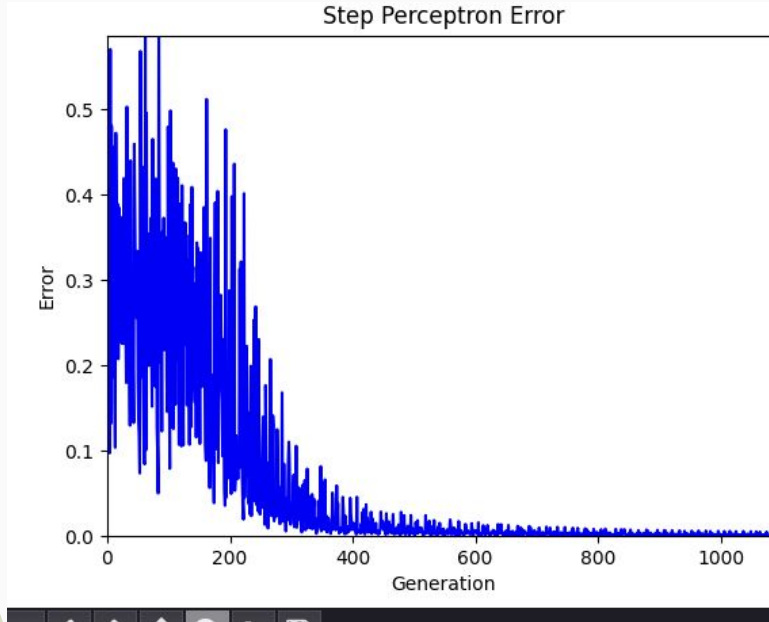


- Un nodo inicial por input
- Dos nodos intermedios
- Unico nodo final
- Tasa de aprendizaje de 0.1



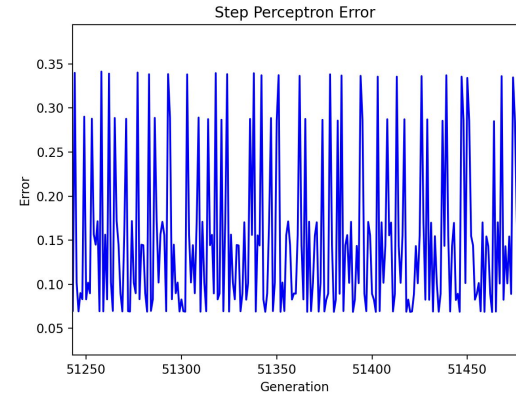


# Funcion PAR

- Un nodo inicial por cada "pixel" (7x5)
- Dos capas intermedias de 10 y 5 nodos respectivamente + bias en cada capa
- Unico nodo final (par o impar)
- Tasa de aprendizaje de 0.1




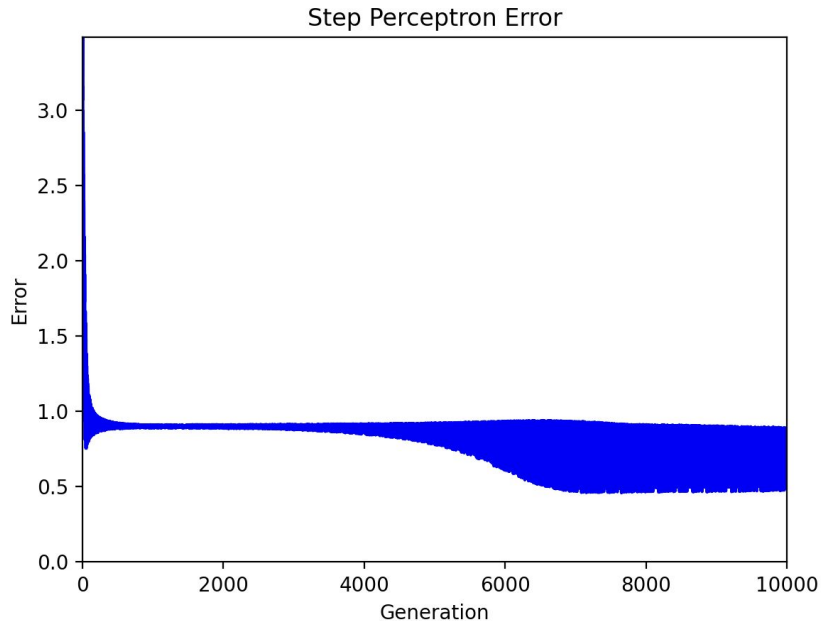
# Funcion NUMBER

- Un nodo inicial por cada "pixel" (7x5)
- Dos capas intermedias de 20 y 15 nodos respectivamente + bias en cada capa
- 10 nodos finales (uno para cada número posible)
- Tasa de aprendizaje de 0.1



# Función NUMBER con más neuronas

- Un nodo inicial por cada “pixel” (7x5)
- 4 capas intermedias de 20, 15, 10 y 10 neuronas respectivamente
- Unico nodo final (par o impar)
- Tasa de aprendizaje de 0.1



# Funcion NUMBER modificando la entrada de testeo ( $\eta=0.01$ , max\_gen=10000)

0	0	1	0	0
0	1	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	1	1	1	0

Output: 0.989

0	0	1	0	0
0	1	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
0	0	1	0	0
1	1	1	1	1

Output: 0.951

[0.02456512784112388,  
**0.9511763216951983**,  
0.051938191669900336,  
0.09183692027195284,  
0.00033930331488810794,  
0.04888153528028594,  
0.022396364953118676,  
0.055789033930245554,  
0.00190426705474464532,  
0.09671389055833823]

# Funcion NUMBER modificando la entrada de testeo ( $\eta=0.01$ , max\_gen=10000)

0	1	1	1	0
1	0	0	0	1
0	0	0	0	1
0	0	1	1	0
0	0	0	0	1
1	0	0	0	1
0	1	1	1	0

Output: 0.982

1	1	1	1	1
1	0	0	0	1
0	0	0	0	1
0	0	1	1	1
0	0	0	0	1
1	0	0	0	1
1	1	1	1	1

Output: 0.922

[0.03157905214412388,  
0.036708911613961436,  
0.04344992027195284,  
**0.9218252214835786,**  
0.000125303968012734,  
0.02375153528028594,  
0.018746364953118676,  
0.047846715604245554,  
0.00017326705474464532,  
0.04407789055833823]

# Conclusiones

- Se puede representar la operación XOR usando dos neuronas de entrada que eventualmente convergen en una neurona de salida
- Modificar un poco el bitmap que se usó para entrenar el modelo no modifica la salida. Sin embargo, al tratarse de poca cantidad de “píxeles”, un par de cambios puede alterar mucho la salida esperada
- Incrementar la cantidad de nodos/layers no necesariamente lleva a un error menor